

ESTUDIO EN LA DISIPACIÓN Y MODELADO EN UNA TRAMPA ARMÓNICA EN EL RÉGIMEN CUÁNTICO

Agustín Agote y Maximiliano Murgia

23 de junio de 2026

PROYECTO NRO. 21

Resumen

En el trabajo presente, se estudió la dinámica de una nanopartícula levitada en equilibrio térmico en una trampa óptica rotante. La misma fue modelada mediante una ecuación de Lindblad que incorpora la interacción con el entorno y los mecanismos de disipación relevantes. A partir de aquí, se desarrolló una implementación numérica para simular la evolución temporal de los momentos de posición e impulso de la partícula. Se generó un conjunto de datos sintéticos y se entrenó una red neuronal para resolver el problema inverso de identificación de parámetros a partir de observables accesibles experimentalmente. Los resultados revelan que la red es capaz de estimar con buena precisión los parámetros dinámicos del sistema, incluso en presencia de fluctuaciones estocásticas en la frecuencia de rotación. Un segundo estudio sobre el mismo sistema incorporó sistemas de retroalimentación a la trampa. La dinámica resultante para los momentos de las distribuciones de posición y momento pudo ser modelada mediante filtros de Kalman extendidos. Se pudieron afrontar diferentes problemas de optimización basados en funcionalidad directa e inversa de estos modelos, pudiendo realizar inferencia de parámetros y predecir características de la dinámica del sistema.

1. Introducción

Los sistemas optomecánicos levitados han emergido en los últimos años como una de las plataformas más prometedoras para el estudio de fenómenos cuánticos a escalas mesoscópicas. Gracias al notable avance en las técnicas de atrapamiento óptico y eléctrico, se han alcanzado hitos experimentales tales como el enfriamiento cercano al estado fundamental de movimiento [1–7], la deslocalización del centro de masa (CoM) [8, 9], la generación de estados comprimidos (*squeezed states*) [10, 11], la observación de interacciones entre partículas [12–14] y el desarrollo de protocolos de metrología de alta sensibilidad [15, 16]. Estas capacidades convierten a las nanopartículas levitadas en una herramienta de gran interés tanto para investigaciones fundamentales como para futuras tecnologías cuánticas.

El confinamiento de partículas mediante campos electromagnéticos constituye una técnica ampliamente utilizada en física atómica, molecular y de nanopartículas. Mientras que las partículas cargadas pueden atraparse mediante potenciales eléctricos variables en el tiempo, como ocurre en las trampas de Paul [17, 18], las partículas neutras pueden ser confinadas utilizando campos ópticos altamente focalizados, conocidos como pinzas ópticas, aunque las primeras propuestas fueron con la utilización de láseres [19–22]. Más recientemente, se han propuesto configuraciones híbridas que combinan confinamiento óptico y eléctrico con el objetivo de ampliar las posibilidades experimentales para el estudio de objetos mesoscópicos en el régimen cuántico [8, 9, 23].

Una de las principales motivaciones para estudiar sistemas levitados radica en la posibilidad de explorar la transición entre el comportamiento cuántico y clásico de la materia. Las nanopartículas levitadas en ultra-alto vacío presentan un elevado grado de aislamiento respecto de su entorno, permitiendo preparar estados cuánticos mediante la deslocalización de su centro de masa y manipularlos de forma controlada [24]. Esto abre la puerta a experimentos que investigan la coherencia cuántica en objetos cuyo tamaño y masa son varios órdenes de magnitud mayores que los sistemas tradicionalmente utilizados en óptica cuántica.

Sin embargo, la observación de efectos cuánticos en sistemas macroscópicos se encuentra limitada por los procesos de decoherencia. La interacción entre el sistema y su entorno provoca una pérdida progresiva de coherencia cuántica debido al entrelazamiento con un gran número de grados de libertad ambientales [25–28]. Este fenómeno ha sido estudiado experimentalmente en interferometría de materia y/o con acoplamiento de fotones externos [29–34], sistemas de iones atrapados [35] y estados coherentes fotónicos [36]. En particular, la emisión de radiación térmica constituye un mecanismo universal de decoherencia capaz de destruir las interferencias cuánticas incluso en ausencia de otras fuentes externas de perturbación [37].

En el caso de las nanopartículas ópticamente levitadas, las principales fuentes de calentamiento y decoherencia incluyen las colisiones con moléculas residuales del gas, el retroceso asociado a la dispersión de fotones (*photon recoil*) y la emisión de radiación térmica por parte de la partícula [38]. A presiones suficientemente bajas, las colisiones con el gas pueden volverse despreciables, haciendo que los mecanismos ópticos constituyan la principal limitación para la preservación de la coherencia

cuántica [39]. Comprender cuantitativamente estos procesos resulta esencial para el desarrollo de experimentos de precisión y futuras aplicaciones tecnológicas basadas en sistemas optomecánicos levitados.

Para limitar los efectos de calentamiento en el sistema, se puede hacer uso de distintas técnicas de enfriado. Una de las más comunes para nanopartículas levitadas es la de *feedback-cooling*. Esta consiste en el aprovechamiento de información sobre el estado del sistema, provista por ejemplo por los canales de decoherencia presentados anteriormente, para aplicar protocolos que resten a la energía del mismo [40, 41].

En este trabajo se estudia la dinámica cuántica de una nanopartícula atrapada en un potencial óptico rotante. En primer lugar se modelan los mecanismos de disipación mediante una ecuación maestra del tipo Lindblad. A partir de simulaciones numéricas, se generan trayectorias temporales de distintos observables físicos del sistema. Posteriormente, se emplean técnicas de aprendizaje automático para inferir parámetros relevantes de la dinámica, como las tasas de decoherencia y la frecuencia de rotación de la trampa. Finalmente, se estiman las incertidumbres asociadas a dichos parámetros, evaluando la robustez de la inferencia frente a la presencia de ruido experimental. En segundo lugar se estudian mecanismos de *feedback-cooling* en la misma trampa mediante un sistema de ecuaciones diferenciales estocásticas. La dinámica del sistema se caracteriza mediante la integración numérica para la generación de trayectorias y el empleo de filtros de Kalman para el análisis de las mismas. A partir de estas técnicas, se resuelven problemas de optimización inversa, como la inferencia de parámetros relevantes al enfriado del sistema, y directa, como la optimización de la fuerza retroalimentada al sistema para maximizar su enfriamiento.

2. Descripción del modelo y técnicas utilizadas

2.1. Dinámica de la trampa tipo *saddle*

La dinámica de una trampa óptica tipo *saddle* [42] se basa en la modulación temporal de un potencial que alterna entre configuraciones confinantes y anti-confinantes a lo largo de direcciones ortogonales. Aunque instantáneamente una de las direcciones presenta un comportamiento inestable, la rápida rotación del potencial da lugar a un confinamiento efectivo promedio, análogo al mecanismo de estabilización dinámica que opera en las trampas de Paul.

La realización experimental de este esquema puede obtenerse mediante una familia de potenciales ópticos generados, dentro de la aproximación paraxial, a partir de una superposición coherente de tres modos Laguerre-Gauss (LG). El campo eléctrico total de la trampa puede escribirse como:

$$\frac{E_{tw}}{E_0} = \sqrt{I_G} E_{0,0}^{\text{LG}} + \sqrt{\frac{I_L}{2}} E_{0,2}^{\text{LG}} e^{-i2\theta} + \sqrt{\frac{I_L}{2}} E_{0,-2}^{\text{LG}} e^{i2\theta} \quad (1)$$

donde $E_{p,l}^{\text{LG}}$ representa un modo Laguerre-Gauss con índice radial p e índice azimutal l , mientras que $E_0 = \sqrt{\frac{2P}{c\epsilon_0}}$ es el factor de normalización asociado a la potencia óptica total P . Los parámetros I_G e I_L describen la fracción de potencia contenida en las componentes gaussiana ($l = 0$) y Laguerre ($l = \pm 2$), respectivamente, satisfaciendo la condición $I_G + I_L = 1$. Por su parte, el parámetro θ corresponde a una fase relativa controlable entre los distintos modos ópticos. En consecuencia, la geometría y propiedades dinámicas del potencial resultante pueden ajustarse mediante la elección de I_G , I_L y θ .

Si la fase relativa evoluciona linealmente en el tiempo según $\theta = \Omega t$, el campo definido en la ecuación (1) genera un potencial rotante del tipo *saddle*, representado esquemáticamente en la Figura 1. En la vecindad del eje óptico, el movimiento longitudinal puede aproximarse como un oscilador desacoplado de la dinámica transversal. Bajo esta aproximación, el sistema constituye una trampa tridimensional estable para una nanopartícula dieléctrica siempre que la frecuencia de rotación supere un valor crítico Ω_0 [42]. Físicamente, esta condición garantiza que la rotación del potencial sea lo suficientemente rápida como para compensar las regiones instantáneamente anti-confinantes, produciendo un confinamiento dinámico efectivo. Por debajo de dicho umbral, la estabilidad se pierde y la partícula deja de permanecer atrapada.

Suponiendo desacoplados los grados de libertad longitudinales y transversales, y restringiéndonos a desplazamientos suficientemente pequeños alrededor del equilibrio, la dinámica puede estudiarse únicamente en el plano $x - y$. En esta situación, la nanopartícula experimenta un potencial cuadrático cuya orientación rota con frecuencia angular Ω . Desde el sistema de referencia del laboratorio, dicha rotación introduce términos dependientes del tiempo que acoplan los movimientos en ambas direcciones espaciales. Como resultado, la evolución del centro de masa queda determinada por la competencia entre el confinamiento efectivo promedio, el acoplamiento entre modos y los efectos inducidos por la rotación de la trampa. El potencial puede escribirse entonces como:

$$V(x, y, t) = V_0 [k_-(t)x^2 + k_+(t)y^2 - k_{xy}(t)xy] \quad (2)$$

en donde:

$$V_0 \equiv \frac{2\Re[\alpha]P}{c\pi w_0^4 \epsilon_0} \quad , \quad w_0 \equiv \frac{\lambda}{\pi \text{NA}} \quad , \quad \alpha \equiv 4\pi\epsilon_0 R^3 \frac{n^2 - 1}{n^2 + 2} \quad (3)$$

siendo ϵ_0 la permitividad eléctrica del vacío, n el índice de refracción, R el radio de la nanopartícula, α la polarizabilidad de la partícula, w_0 el parámetro de *cintura* del modo gaussiano, NA la apertura numérica del haz, λ la longitud de onda del




Figura 1: Trampa óptica tipo *saddle*. La rotación de la misma con cierta frecuencia $\Omega \geq \Omega_0$ permite que la partícula se encuentre confinada de manera efectiva a pesar de presentar instantáneamente una dirección anti-confinante.

haz utilizado y:

$$k_{\pm}(t) = I_G \pm 2\sqrt{I_L I_G} \cos(2\Omega t) \quad (4)$$

$$k_{xy}(t) = 4\sqrt{I_L I_G} \sin(2\Omega t) \quad (5)$$

La naturaleza cuadrática del potencial garantiza que los estados gaussianos permanezcan gaussianos durante la evolución. Sin embargo, el término de acoplamiento proporcional a $k_{xy}(t)$ induce correlaciones cuánticas entre las coordenadas ortogonales x e y , dando lugar a la generación de entrelazamiento entre ambos grados de libertad. Asimismo, la dinámica produce fenómenos de *squeezing* en las variables conjugadas de momento lineal.

La aproximación cuadrática descrita por la ecuación (2) resulta válida siempre que el desplazamiento transversal de la partícula $d_{\perp}$ satisfaga la condición:

$$d_{\perp} \ll \frac{w_0}{\sqrt{1 + 2\sqrt{I_L/I_G}}} \quad (6)$$

de modo que las contribuciones no lineales del potencial puedan despreciarse [43]. Una caracterización detallada de la geometría y propiedades dinámicas de la trampa *saddle* puede encontrarse en [42], mientras que un análisis exhaustivo de la validez de la aproximación cuadrática se presenta en [39].

En este trabajo, adoptaremos un conjunto de parámetros inspirado en propuestas y realizaciones experimentales recientes [38, 39, 42]. Consideramos una nanopartícula de radio $R = 50$ nm que, asumiendo una composición de silicio, posee una masa aproximada de $m \simeq 1,22 \times 10^{-18}$ kg. Se tomó un índice de refracción $n = 1,45$. La potencia parcial correspondiente al haz gaussiano será $I_G = 0,3$ y la potencia total del haz utilizado $P = 70$ mW. La apertura numérica fue tomada como $\text{NA} = 0,6$. Por otro lado, la longitud de onda del haz utilizado será $\lambda = 1550$ nm. La frecuencia de giro de la trampa se eligió de manera que sea $\Omega = 5\Omega_0$, siendo [42]:

$$\Omega_0 = 2\sqrt{\frac{V_0}{w_0^2 m} [I_G + 2\sqrt{I_G I_L}]} \quad (7)$$

Con estos parámetros elegidos, queda unívocamente determinadas las demás constantes definidas anteriormente.

La partícula se encuentra inicialmente confinada en una pinza óptica gaussiana caracterizada por una frecuencia transversal de atrapamiento $\Omega_q = 150$ kHz, con amplitud de fluctuación del estado fundamental $q_{\text{zpf}} = \sqrt{\hbar/(2m\Omega_q)}$ para $q \in \{x, y\}$. La partícula es preparada en un cierto estado térmico con bajo número de ocupación, siendo $\bar{n}_x = \bar{n}_y = 0,8$, siguiendo cada nivel de energía la estadística de Boltzmann. A tiempo $t = 0$ este estado se transfiere a la trampa *saddle*, evolucionando posteriormente de acuerdo con una ecuación maestra de Lindblad dada por:

$$\frac{d\hat{\rho}}{dt} = \frac{1}{i\hbar}[\hat{H}, \hat{\rho}] - \frac{\Gamma_x}{x_{\text{zpf}}^2}[\hat{x}, [\hat{x}, \hat{\rho}]] - \frac{\Gamma_y}{y_{\text{zpf}}^2}[\hat{y}, [\hat{y}, \hat{\rho}]] \quad (8)$$

donde $\hat{H}$ es el Hamiltoniano de la partícula, considerando su contribución cinética y el potencial cuadrático definido en (2):

$$\hat{H} = \frac{\hat{p}_x^2 + \hat{p}_y^2}{2m} + V(\hat{x}, \hat{y}, t) \quad (9)$$

Los términos con doble conmutador describen la interacción irreversible del sistema con su entorno bajo una aproximación markoviana. Las constantes Γ_q , con $q \in \{x, y\}$, representan las tasas efectivas de decoherencia asociadas a cada dirección espacial y producen una progresiva localización de la función de onda de la partícula [44].

Los principales mecanismos responsables de la pérdida de coherencia cuántica son las colisiones con moléculas residuales del gas, el calentamiento por retroceso de fotones (*photon recoil heating*) [38] y la emisión de radiación térmica por parte de la nanopartícula [37]. En condiciones de ultra-alto vacío, con presiones inferiores a 10^{-9} mbar, la contribución debida a las colisiones gaseosas puede reducirse hasta tasas del orden de $\Gamma_{\text{gas}} \approx 100$ Hz, correspondientes a tiempos característicos cercanos a $T_{\text{gas}} \approx 10$ ms. Este tiempo supone una cota máxima para la duración de los experimentos donde las decoherencias debidas a este fenómeno pueden ser despreciadas.

Por otro lado, los mecanismos asociados a la dispersión y absorción de fotones constituyen una limitación intrínseca de los sistemas de atrapamiento óptico. Una de las ventajas más relevantes de las trampas *saddle* es que permiten minimizar significativamente estos efectos. Mediante una elección adecuada de las intensidades relativas de los modos Laguerre-Gauss, las componentes con $l = \pm 2$ del campo utilizado en la ecuación (1) generan una región de intensidad mínima (*dark region*) alrededor de la posición de equilibrio. Como consecuencia, la partícula permanece confinada en una zona donde la dispersión de fotones se encuentra fuertemente reducida, suprimiendo notablemente los procesos de *photon recoil heating* [39]. Así, la tasa de decoherencia Γ_q debido al proceso de *photon recoil* para la dirección q es [38]:

$$\Gamma_q = C_q \frac{64 I_G P |\alpha|^2}{15 m c \Omega_q \lambda^5 w_0^2 \epsilon_0^2}, \quad (10)$$

donde:

$$\mathbf{C} = \left[\frac{1}{5}, \frac{2}{5} \right] \quad (11)$$

es un factor geométrico debido a la manera anisotrópica en la cual la energía es transferida a la partícula por medio de este mecanismo [45].

2.2. Trampa armónica con ruido estocástico

La dinámica de la nanopartícula fue simulada resolviendo numéricamente la ecuación maestra de Lindblad presentada en la ecuación (8). Dado que el potencial considerado es cuadrático en las coordenadas transversales, el sistema puede describirse mediante dos grados de libertad independientes asociados a las direcciones x e y .

Para representar los operadores cuánticos de posición e impulso lineal, se truncó el espacio de Hilbert de cada coordenada a una dimensión finita D . La elección de dicho valor se realizó estudiando la convergencia de observables relevantes, en particular los segundos momentos:

$$\langle \hat{x}^2(t) \rangle, \quad \langle \hat{y}^2(t) \rangle, \quad \langle \hat{p}_x^2(t) \rangle, \quad \langle \hat{p}_y^2(t) \rangle$$

Se aumentó progresivamente el tamaño de la base hasta verificar que los resultados no presentaran variaciones apreciables. A partir de este análisis, se adoptó $D = 30$ para cada dirección, por lo que el espacio de Hilbert total quedó definido como el producto tensorial de ambos subespacios.

La evolución temporal fue calculada entre $t = 0$ y $t = 100 \mu\text{s}$. Este intervalo temporal fue elegido debido a que constituye una escala compatible con los tiempos característicos de decoherencia producidos por colisiones con gases residuales en condiciones de ultra-alto vacío, evitando así ingresar en un régimen donde dichos procesos dominan la dinámica observada. Inicialmente se emplearon 2500 puntos temporales para verificar la convergencia de la integración numérica. Posteriormente, se comprobó que una discretización de 300 puntos era suficiente para reproducir adecuadamente la dinámica de los observables estudiados, reduciendo significativamente el costo computacional.

Durante cada simulación, se calcularon los valores medios $\langle \hat{x}(t) \rangle$, $\langle \hat{y}(t) \rangle$, $\langle \hat{p}_x(t) \rangle$ y $\langle \hat{p}_y(t) \rangle$, junto con los segundos momentos $\langle \hat{x}^2(t) \rangle$, $\langle \hat{y}^2(t) \rangle$, $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$. Debido a la simetría del problema y a las condiciones iniciales consideradas, los primeros momentos permanecen nulos durante toda la evolución, por lo que la información relevante para la caracterización del sistema se encuentra contenida en los segundos momentos.

Se generaron 10 simulaciones independientes del problema directo. Para cada realización se almacenaron las series temporales de los observables $\langle \hat{x}^2(t) \rangle$, $\langle \hat{y}^2(t) \rangle$, $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$. Dado que cada observable fue registrado en 300 instantes temporales, cada simulación quedó representada mediante un vector de entrada de dimensión $4 \times 300 = 1200$.

2.2.1. Incorporación de ruido estocástico

Con el objetivo de aproximar de manera más realista las condiciones experimentales, se consideró que la frecuencia de rotación de la trampa no permanece estrictamente constante durante la evolución. Para ello, se definió una frecuencia efectiva $\Omega_{\text{eff}}(t)$:

$$\Omega_{\text{eff}}(t) = \Omega + \xi(t) \quad (12)$$

donde $\xi(t)$ corresponde a un proceso estocástico de Ornstein-Uhlenbeck. Este proceso satisface la ecuación diferencial estocástica:

$$\frac{d\xi(t)}{dt} = -\frac{\xi(t)}{\tau_c} dt + \sigma \sqrt{\frac{2}{\tau_c}} dW_t \quad (13)$$

donde τ_c representa el tiempo de correlación del ruido, σ su amplitud característica (la desviación estándar de la distribución estacionaria) y dW_t un proceso de Wiener. A diferencia del ruido blanco, el proceso de Ornstein-Uhlenbeck posee correlaciones temporales finitas, constituyendo una descripción más realista de fluctuaciones presentes en sistemas experimentales.

La fase que controla la orientación instantánea de la trampa se calculó entonces mediante:

$$\phi(t) = \int_0^t dt' \Omega_{\text{eff}}(t') \quad (14)$$

reemplazando la dependencia ideal $\phi(t) = \Omega t$. La incorporación de este ruido permite generar trayectorias sintéticas que conservan las características generales de la dinámica estudiada, pero presentan fluctuaciones comparables a las que podrían observarse en una medición experimental real.

Para incrementar la diversidad de las simulaciones se permitió además que las tasas de decoherencia Γ_x y Γ_y , así como los parámetros del ruido de Ornstein-Uhlenbeck, fluctuaran entre distintas realizaciones. Cada uno de estos parámetros $p \in \{\Gamma_x, \Gamma_y, \tau_c, \sigma\}$ fue muestreado a partir de una distribución normal:

$$p \sim N(p, (0, 1p)^2)$$

de modo que la desviación estándar corresponde al 10 % de su valor medio.

2.2.2. Arquitectura y entrenamiento de una red neuronal

Se diseñó y entrenó una red neuronal (NN) que fuera capaz de resolver el problema inverso del sistema. Es decir, a partir de las series temporales de los segundos momentos $\langle \hat{x}^2(t) \rangle$, $\langle \hat{y}^2(t) \rangle$, $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$, poder inferir los parámetros Γ_x, Γ_y y Ω que rigen la dinámica, a pesar de la presencia del ruido estocástico en la frecuencia de rotación. Para ello, los parámetros físicos asociados a cada simulación:

$$(\Gamma_x, \Gamma_y, \Omega)$$

constituyeron las salidas utilizadas durante el entrenamiento supervisado de la red neuronal. Antes del entrenamiento, tanto las entradas como las salidas fueron normalizadas utilizando la media y desviación estándar calculadas sobre el conjunto de datos completo.

La arquitectura adoptada posee una entrada de 1200 neuronas, correspondientes a las series temporales concatenadas de los cuatro observables estudiados. A continuación, la información es procesada mediante tres capas ocultas de dimensiones:

$$1200 \longrightarrow 512 \longrightarrow 256 \longrightarrow 128 \longrightarrow 3$$

donde las tres neuronas de salida representan las estimaciones de Γ_x, Γ_y y Ω . En todas las capas ocultas se empleó la función de activación ReLU ($f(x) = \max(0, x)$) que introduce la no linealidad necesaria para modelar la relación entre observables y parámetros físicos.

El entrenamiento se realizó utilizando el algoritmo de optimización Adam y una función de costo basada en el error cuadrático medio (MSE):

$$L_{\text{loss}} = \frac{1}{N} \sum_{i=1}^N (y_i - y_i^*)^2, \quad (15)$$

donde y_i representa la predicción realizada por la red neuronal para cada parámetro físico y y_i^* el correspondiente valor utilizado durante el entrenamiento. La cantidad N representa el número total de componentes consideradas en la evaluación de la pérdida.

La elección de esta función de costo se fundamenta en que, en ausencia de información detallada sobre el origen físico de las fluctuaciones presentes en los datos, resulta razonable asumir errores aproximadamente gaussianos. Bajo esta hipótesis, la minimización del error cuadrático medio equivale a maximizar la verosimilitud de las observaciones. La utilización del error cuadrático medio penaliza de manera más severa las predicciones con errores grandes que aquellas con errores pequeños, favoreciendo así una reconstrucción globalmente consistente de los parámetros físicos del sistema. Luego, utilizando el mecanismo de *backpropagation*, los pesos y sesgos de la red fueron actualizados iterativamente con el objetivo de minimizar la función de costo.

2.2.3. Estimación de errores en los parámetros y extensión del modelo

La incertidumbre asociada a los parámetros inferidos fue estimada partiendo de cada conjunto de datos sintéticos considerado como medición experimental. Con ello, se agregó ruido gaussiano independiente a cada punto temporal de las curvas observadas y se generaron 10^4 réplicas artificiales a partir de estas.

Se asumió una incertidumbre relativa de 10^{-4} para cada medición. Cada réplica fue procesada por la red neuronal entrenada obteniendo una nueva estimación de los parámetros Γ_x , Γ_y y Ω . La distribución de valores resultante permitió calcular medias, desviaciones estándar e intervalos de confianza para cada parámetro estimado. De esta forma, la dispersión observada en las predicciones de la red proporciona una estimación cuantitativa de la incertidumbre propagada desde las mediciones experimentales hacia los parámetros físicos inferidos.

Finalmente, se exploró una segunda arquitectura de red neuronal destinada a inferir simultáneamente los parámetros físicos del sistema y los parámetros característicos del proceso de Ornstein-Uhlenbeck de la ecuación (13). En este caso, la salida de la red se amplió para incluir tanto las tasas de decoherencia y la frecuencia de rotación como las magnitudes asociadas al ruido estocástico, permitiendo estudiar hasta qué punto la información contenida en los segundos momentos es suficiente para caracterizar no sólo la dinámica promedio del sistema sino también las fluctuaciones que la afectan.

2.3. Trampa armónica con monitoreo *feedback-cooling*

Se consideró también una segunda configuración de la trampa armónica agregando un sistema de medición continua de la posición o el momento de la partícula en la trampa. La mecánica cuántica prohíbe la medición sin interacción con el sistema, por lo que esta inclusión trae consecuencias sobre la dinámica de la partícula. Por una parte, el mecanismo de medición actúa para localizar en posición y momento, de manera limitada por el principio de incerteza de Heisenberg y las distintas fuentes de decoherencia del sistema. Por otra parte, luego de una medición, el sistema se reconfigura de forma tal que el valor medio de la posición o momento sea compatible con el valor medido. Estos efectos llevaron a una descripción efectiva del sistema basada en ecuaciones diferenciales estocásticas. Estas ecuaciones son, para los valores medios de posición y momento [39],

$$\begin{aligned} d\langle \vec{x} \rangle &= \frac{1}{m} \langle \vec{p} \rangle dt + G_{\vec{x}} \cdot d\vec{W}, & d\langle \vec{p} \rangle &= -\langle \vec{\nabla} V \rangle dt + G_{\vec{p}} \cdot d\vec{W}, \\ G_{\vec{x}} &= \begin{pmatrix} \sqrt{2\eta_x \Lambda_x} C_{xx} & \sqrt{2\eta_y \Lambda_y} C_{xy} \\ \sqrt{2\eta_x \Lambda_x} C_{xy} & \sqrt{2\eta_y \Lambda_y} C_{yy} \end{pmatrix}, & G_{\vec{p}} &= \begin{pmatrix} \sqrt{2\eta_x \Lambda_x} C_{px} & \sqrt{2\eta_y \Lambda_y} C_{py} \\ \sqrt{2\eta_x \Lambda_x} C_{py} & \sqrt{2\eta_y \Lambda_y} C_{px} \end{pmatrix}. \end{aligned} \quad (16)$$

en donde $\Lambda_x = \Gamma_x/x_{pff}^2$, $\Lambda_y = \Gamma_y/y_{pff}^2$, C es la matriz de covarianza de la posición y el momento y $d\vec{W}$ representa el incremento de dos procesos de Wiener. A su vez, esta última evoluciona de acuerdo al sistema,

$$\begin{aligned} \frac{dC_{xx}}{dt} &= \frac{2}{m} C_{pxx} - 2\eta_x \Lambda_x C_{xx}^2 - 2\eta_y \Lambda_y C_{xy}^2, \\ \frac{dC_{yy}}{dt} &= \frac{2}{m} C_{pyy} - 2\eta_x \Lambda_x C_{xy}^2 - 2\eta_y \Lambda_y C_{yy}^2, \\ \frac{dC_{p_x p_x}}{dt} &= -2 \langle p_x \partial_x V \rangle + 2\hbar^2 \Lambda_x - 2\eta_x \Lambda_x C_{p_x p_x}^2 - 2\eta_y \Lambda_y C_{y p_x}^2, \\ \frac{dC_{p_y p_y}}{dt} &= -2 \langle p_y \partial_y V \rangle + 2\hbar^2 \Lambda_y - 2\eta_x \Lambda_x C_{x p_y}^2 - 2\eta_y \Lambda_y C_{p_y p_y}^2, \\ \frac{dC_{xy}}{dt} &= \frac{1}{m} (C_{x p_y} + C_{y p_x}) - 2\eta_x \Lambda_x C_{xy} C_{xx} - 2\eta_y \Lambda_y C_{xy} C_{yy}, \\ \frac{dC_{p_x p_y}}{dt} &= -(\langle p_y \partial_x V \rangle + \langle p_x \partial_y V \rangle) - 2\eta_x \Lambda_x C_{p_x p_x} C_{p_y p_x} - 2\eta_y \Lambda_y C_{p_y p_x} C_{p_x p_y}, \\ \frac{dC_{x p_x}}{dt} &= \frac{1}{m} C_{p_x p_x} - \langle x \partial_x V \rangle - 2\eta_x \Lambda_x C_{xx} C_{x p_x} - 2\eta_y \Lambda_y C_{xy} C_{y p_x}, \\ \frac{dC_{y p_y}}{dt} &= \frac{1}{m} C_{p_y p_y} - \langle y \partial_y V \rangle - 2\eta_x \Lambda_x C_{xy} C_{x p_y} - 2\eta_y \Lambda_y C_{yy} C_{y p_y}, \\ \frac{dC_{x p_y}}{dt} &= \frac{1}{m} C_{p_x p_y} - \langle x \partial_y V \rangle - 2\eta_x \Lambda_x C_{xx} C_{x p_y} - 2\eta_y \Lambda_y C_{xy} C_{y p_y}, \\ \frac{dC_{y p_x}}{dt} &= \frac{1}{m} C_{p_y p_x} - \langle y \partial_x V \rangle - 2\eta_x \Lambda_x C_{xy} C_{x p_x} - 2\eta_y \Lambda_y C_{yy} C_{y p_x}. \end{aligned} \quad (17)$$

Dado que la fuerza producida por el potencial $-\langle \nabla V \rangle$ es lineal, los términos en que esta aparece solo involucrarán los primeros momentos de las variables en las ecuaciones para los primeros momentos o los segundos en las ecuaciones para los segundos momentos. Esto hace que este sistema de ecuaciones sea cerrado y que, en particular, las ecuaciones para las componentes de la matriz de covarianza formen también un sistema cerrado de ecuaciones diferenciales, en este caso deterministas. Esto se explotó resolviendo este sistema por separado al de los valores medios, luego utilizando estas soluciones como parámetros del sistema estocástico.

Sobre este sistema de ecuaciones se agregó un mecanismo de *feedback-cooling*. Este consistió en elaborar una estimación $\vec{q}$ del momento $\vec{p}$ a partir de las mediciones realizadas y aplicar una fuerza contraria al mismo. En un régimen en que $\vec{q} \sim \vec{p}$, esto resta energía al sistema, enfriándolo. Matemáticamente, esto se incorporó al modelo modificando las ecuaciones para el valor medio del momento del sistema y agregando una variable auxiliar:

$$d\langle \vec{p} \rangle = - \left[\langle \vec{\nabla} V \rangle + U \cdot \vec{q} \right] dt + G_{\vec{p}} \cdot d\vec{W}, \quad U = \begin{pmatrix} u_x & 0 \\ 0 & u_y \end{pmatrix}, \quad (18)$$

$$d\langle \vec{q} \rangle = -\tilde{U} \cdot (\vec{q} - \vec{p})dt + \vec{G}_{\vec{q}} dW_{\vec{q}}, \quad \tilde{U} = \begin{pmatrix} v_x & 0 \\ 0 & v_y \end{pmatrix}, \quad \vec{G}_{\vec{q}} = \begin{pmatrix} \epsilon_x \\ \epsilon_y \end{pmatrix}. \quad (19)$$

Este modelo describe como el momento estimado $\vec{q}$ tiende al momento real $\vec{p}$ con velocidad dada por $\tilde{U}$, pero con un ruido adicional cuya magnitud está dada por $\vec{G}_{\vec{q}}$. El *feedback-cooling* proviene de una fuerza proporcional y opuesta a $\vec{q}$ sobre el sistema, cuya magnitud está gobernada por U . El modelo puede ser mejorado de diversas formas, en especial en cuanto al modelado del ruido, que en este caso depende de un único proceso de Wiener distinto a los que aparecen en las ecuaciones de la posición y el momento. Al provenir el ruido en el sistema justamente de las mediciones, se debería hacer un estudio más profundo de cómo la forma del ruido aplicado al momento estimado se relaciona con el que aparece en la posición y momento.

En cuanto al modelo observacional, se consideró que el experimentador tuvo acceso a mediciones ruidosas de la posición realizadas a una alta frecuencia de muestreo de 20 MHz. El ruido aplicado a las mediciones de posición fue gaussiano con una varianza idéntica en ambos ejes de movimiento dada por σ^2 . Los valores numéricos de los parámetros introducidos en esta región se escogieron como $u_x = u_y = 0,1 \mu\text{s}^{-1}$, $v_x = v_y = 0,1 \mu\text{s}^{-1}$, de forma tal que el tiempo característico del decaimiento del momento y del momento estimado fuese de $10\mu\text{s}$. Los parámetros que rigen sobre el error en la estimación del momento se eligieron $\epsilon_x = \epsilon_y = 10^{-9} \frac{\text{ev}\sqrt{\mu\text{s}}}{\text{nm}}$, tal que la incerteza típica en el momento estimado en el caso estacionario fuese de $2,2 \cdot 10^{-9} \frac{\text{ev}\mu\text{s}}{\text{nm}}$, valor un orden de magnitud menor que el momento inicial típico. La incerteza en las mediciones de posición se tomó de $\sigma = 0,005 \text{ nm}$, valor pequeño pero experimentalmente accesible [40, 41].

2.3.1. Integración numérica

En este trabajo se utilizaron dos formas de analizar el comportamiento del sistema. La primera, utilizada para muestrear trayectorias del sistema fue la integración numérica directa de las ecuaciones diferenciales estocásticas. La segunda, de validez más acotada, fue la de filtros de Kalman. utilizada para resolver problemas de optimización directos e inversos sobre las trayectorias y los parámetros del sistema.

La generación de trayectorias se realizó según un método de Euler-Mauryama modificado. El método de Euler-Mauryama consiste en realizar la integración numérica de una ecuación diferencial estocástica discretizando el paso temporal y considerando el siguiente esquema para los actualizar el estado a cada paso:

$$d\vec{u}(t) = \vec{f}(\vec{u}, t)dt + G(\vec{u}, t) \cdot d\vec{W} \xrightarrow{dt \rightarrow \Delta t} \vec{u}(t_{i+1}) - \vec{u}(t_i) = \vec{f}(\vec{u}(t_i), t_i)\Delta t + G(\vec{u}(t_i), t_i) \cdot \Delta\vec{W}, \quad (20)$$

en donde $\Delta\vec{W} \sim N(\vec{0}, \Delta t \cdot I_m)$. El orden fuerte del método (que mide como escala el error de las trayectorias generadas respecto a las trayectorias usuales con el paso temporal), es generalmente de 0.5. Sin embargo, en el caso particular de las ecuaciones 20 en que el ruido es *aditivo*, es decir $G(\vec{u}, t) = G(t)$, el orden fuerte crece a ser 1, siendo los términos dominantes del error en la parte estocástica de orden 1.5 y en la parte determinista de orden 2 [46].

El método de Euler-Mauryama resultó adecuado para describir el efecto del ruido sobre el sistema, siendo los términos deterministas y estocásticos considerados por el esquema típicamente dos órdenes de magnitud mayores que los términos dominantes del error de la parte estocástica, considerando que el paso temporal fue determinado por la frecuencia de muestreo. Sin embargo, el método no fue del todo satisfactorio para modelar el sistema debido a su inestabilidad para sistemas oscilatorios que hereda del método de Euler. Para aliviar parcialmente este problema, se modificó el esquema a utilizar, considerando en cambio un método partido:

$$d\vec{u}(t) = \vec{f}_{RK4}(\vec{u}, t)dt + G(\vec{u}, t) \cdot d\vec{W} \xrightarrow{dt \rightarrow \Delta t} \vec{u}(t_{i+1}) - \vec{u}(t_i) = \vec{f}(\vec{u}(t_i), t_i)\Delta t + G(\vec{u}(t_i), t_i) \cdot \Delta\vec{W}. \quad (21)$$

En este, $\vec{f}_{RK4}(\vec{u}, t)$ corresponde al paso temporal predicho por el esquema de Runge-Kutta de orden 4 para la parte determinista de la dinámica. A pesar de ser solo condicionalmente estable para sistemas oscilatorios, su precisión de orden 4 impide que esta inestabilidad se note significativamente. Para mayor seguridad en la obtención de datos (pero no en el análisis) se consideró un paso temporal cuatro veces menor al tiempo de muestreo para la generación de trayectorias.

2.3.2. Ajuste de trayectorias

Un problema con la resolución de problemas de optimización en sistemas estocásticos es la gran cantidad de trayectorias que puede tomar el sistema, que suele escalar exponencialmente con el intervalo de tiempo considerado. De este conjunto de trayectorias, además, suele pasar que la proporción de estas trayectorias útiles no escala como el número de trayectorias, por lo que será exponencialmente pequeña. Por ejemplo, para el problema de calcular la verosimilitud de los parámetros a ajustar de un sistema dado un conjunto de trayectorias observadas $\{\vec{u}_{i,t_i:t_f}^{OBS}(t)\}_{i=1}^N$, se debe calcular:

$$\left\langle L(\theta) | \{\vec{u}_{i,t_i:t_f}^{OBS}\}_{i=1}^N \right\rangle_{\{\vec{u}(t)\}} = \left\langle \sum_{i=1}^N \prod_{j=1}^M e^{-(\vec{u}(t_j) - \vec{u}_i^{OBS}(t_j))^2 / 2\sigma^2} \right\rangle_{\{\vec{u}(t)\}}. \quad (22)$$

En este valor medio respecto a todas las trayectorias posibles para el sistema, las únicas que tendrán un valor considerable son aquellas que pasan cerca de alguna trayectoria observada para todo tiempo (y que no sean muy improbables de acuerdo a las ecuaciones dinámicas). Para afrontar este problema, se puede utilizar el método de filtro de partículas, un tipo de muestreo por importancia. Resumidamente, este consiste en no generar trayectorias para todo el intervalo temporal *a priori*, sino generarlas de a trozos. Luego de generar trayectorias para cada trozo, se evalúa para cada una su relevancia al cálculo del valor medio y se continúa en el paso siguiente únicamente desde aquellas que no sean altamente irrelevantes. A pesar de que este método aminora el costo computacional necesario para obtener un buen estimador del valor medio, este tampoco podrá ser tan bajo, ya que se necesitan generar muchas trayectorias en cada trozo para que el valor medio no sea dominado únicamente por una única trayectoria, por ejemplo.

Como alternativa a esto, en este trabajo se emplearon filtros de Kalman [47, 48]. Estos dan una manera de estimar el estado de un sistema markoviano bajo observaciones ruidosas. A su vez, proveen una manera de estimar la probabilidad de cada trayectoria o el valor medio de funciones sobre el ensamble de trayectorias posibles menos computacionalmente intenso que los filtros de partículas pero más restringido en su validez. En particular, los filtros de Kalman suponen una distribución gaussiana para el estado estimado de un sistema a un cierto tiempo, $\vec{u}_i \sim N(\vec{\mu}_i, C_i)$, mientras que su estado real es $\vec{x}_i$. También se hace la suposición de que a cada paso el sistema evoluciona de acuerdo a un sistema estocástico lineal:

$$\vec{x}_{i+1} = A_i \cdot \vec{x}_i + \vec{b}_i + \vec{w}_i, \quad (23)$$

en donde $\vec{w}_i$ representa un ruido distribuido de acuerdo a $N(\vec{0}, R_i)$. Al ser lineal la evolución la distribución estimada para los estados del sistema permanecerá gaussiana, aunque sus parámetros se actualizan a cada paso como:

$$\vec{\mu}_{i+1} = A_i \cdot \vec{\mu}_i + \vec{b}_i, \quad C_{i+1} = A_i C_i A_i^T + R_i \quad (24)$$

Además del paso temporal, la estimación del estado se debe actualizar en caso de una medición, $\vec{y}_i$, cuya distribución se supone gaussiana centrada alrededor del valor real del estado a ese tiempo $N(H_i \cdot \vec{x}_i, Q_i)$. Aquí la matriz H_i permite por ejemplo que la medición se realice únicamente sobre algunas coordenadas del estado. La actualización del estado estimado se realiza según el teorema de Bayes, resultando en una distribución gaussiana de parámetros:

$$\vec{\mu}'_i = \vec{\mu}_i + K_i \vec{y}_i, \quad C'_i = (I - K_i H_i) C_i, \quad \text{con} \quad K_i = C_i H_i^T S_i^{-1} \quad \text{y} \quad S_i = H_i C_i H_i^T + Q_i. \quad (25)$$

La matriz K_i es la matriz de ganancia de Kalman, y establece cuan importante es la medición frente a la estimación previa del estado. Se puede notar que, al representar cada actualización del estado debido a una medición un caso de inferencia Bayesiana, se puede calcular la verosimilitud total asignada a una trayectoria inferida a partir de datos medidos a partir de la verosimilitud de cada medición de acuerdo a la estimación del estado del sistema. En este sentido, al solo involucrar algunas operaciones matriciales, los filtros de Kalman parecen una versión superadora de los filtros de partículas. De hecho existen resultados que indican que los filtros de Kalman son estimadores óptimos del estado del sistema si este cumple todas las suposiciones realizadas, siendo este condicional la gran barrera a su aplicación en general.

En el caso del sistema de interés, no es difícil notar que este no cumple con las suposiciones realizadas por los filtros de Kalman. En particular, el proceso de evolución del sistema no es lineal (ante la discretización temporal), ni es el ruido gaussiano (es ruido blanco en tiempo continuo, cuya discretización no es simple). Por esto, en este trabajo se emplearon filtros de Kalman *extendidos* [48]. En estos, se considera que la parte determinista de la evolución resulta de un proceso genérico, $\vec{x}_{i+1} = \vec{f}_i(\vec{x}_i) + \vec{w}_i$. A pesar de que, al no ser necesariamente lineal la evolución del sistema esta puede no preservar la gaussianidad de distribuciones, se hace la suposición de que si lo hará. En este caso la actualización del valor medio de la estimación se realiza según la parte determinista de la ecuación dinámica, pero la de la covarianza se realiza de acuerdo a una linealización del sistema:

$$\vec{\mu}_{i+1} = \vec{f}_i(\vec{\mu}_i), \quad C_{i+1} = J_{\vec{f}_i}(\vec{\mu}_i) C_i J_{\vec{f}_i}(\vec{\mu}_i)^T + R_i, \quad (26)$$

en donde $J_{\vec{f}_i}(\vec{\mu}_i)$ es la matriz jacobiana de $\vec{f}_i$ evaluada en el valor medio previo a la actualización. Los filtros de Kalman extendidos pagan por su mayor aplicabilidad con precisión, ya que solo funcionan aproximadamente. En particular, funcionan mejor en cuanto el sistema sea aproximadamente lineal a las escalas espaciales determinadas por C_i , de manera tal que la no-linealidad no afecte la forma de la distribución. En el caso particular de interés, para pasos temporales pequeños, el sistema cumple estas condiciones aproximadamente, como establece el hecho de que este sea aproximable según el método de Euler-Mauryama. Así, el sistema se modeló con este método considerando las mismas modificaciones realizadas al método de simulación numérica, es decir, utilizando como método de actualización para el valor medio de la distribución estimada el paso temporal del método de Runge-Kutta de orden 4 para mejorar la estabilidad del modelo.

3. Resultados

3.1. Trampa armónica con ruido estocástico

Con el objetivo de seleccionar valores adecuados para los parámetros τ_c y σ del proceso de Ornstein-Uhlenbeck definido en la ecuación (13), se realizaron simulaciones comparativas de la ecuación maestra dada por (8) considerando tanto la presencia como la ausencia de ruido estocástico en la frecuencia de rotación de la trampa. El propósito de este análisis

preliminar fue identificar un régimen en el cual las fluctuaciones introducidas por el ruido fueran suficientemente intensas como para producir modificaciones observables en la dinámica, pero sin alterar de manera drástica los mecanismos físicos característicos del sistema. En otras palabras, se buscó un compromiso entre la introducción de efectos estocásticos apreciables y la preservación de la estructura dinámica propia de la trampa *saddle*.

Los resultados obtenidos se muestran en la Figura 2. En la imagen de la izquierda (Figura 2a) se presenta la evolución temporal de los segundos momentos $\langle \hat{x}^2(t) \rangle$ y $\langle \hat{y}^2(t) \rangle$ para el caso determinístico, correspondiente al límite $\sigma \rightarrow 0$ y $\tau_c \rightarrow +\infty$, donde la frecuencia de rotación permanece estrictamente constante ($\xi(t) = 0 \forall t$). En estas condiciones, se observan las oscilaciones características inducidas por la dinámica de la trampa rotante.

Por otro lado, la Figura 2b muestra la evolución de los mismos observables cuando la frecuencia de rotación incorpora fluctuaciones descritas por un proceso de Ornstein-Uhlenbeck. Puede apreciarse que la presencia del ruido modifica tanto la amplitud como la fase de las oscilaciones, generando desviaciones visibles respecto de la trayectoria determinística. Sin embargo, la estructura global de la dinámica permanece reconocible, indicando que el sistema continúa operando dentro del mismo régimen físico y que las fluctuaciones introducidas no dominan completamente la evolución temporal. Para esta simulación, se utilizaron los valores $\tau_c = 0,3 \mu\text{s}$ y $\sigma = 0,3 \mu\text{s}^{-1}$. Con esta elección, se observó que la realización estocástica $\xi(t)$ podía alcanzar valores instantáneos superiores al 25 % de la frecuencia nominal de rotación Ω . Esto representa una perturbación significativa desde el punto de vista experimental, permitiendo evaluar la robustez de la dinámica frente a fluctuaciones relativamente intensas sin abandonar el régimen de confinamiento efectivo de la trampa.





Figura 2: Series temporales para los valores medios de $\langle \hat{x}^2(t) \rangle$ y $\langle \hat{y}^2(t) \rangle$: (a) cuando no hay ruido estocástico ($\xi(t) = 0 \forall t$) y (b) cuando existe ruido estocástico en la frecuencia de rotación de la trampa, utilizando como parámetros $\tau_c = 0,3 \mu\text{s}$ y $\sigma = 0,3 \mu\text{s}^{-1}$.

Una perspectiva complementaria se obtiene al representar la evolución temporal en el espacio de fases definido por los segundos momentos $\langle \hat{x}^2(t) \rangle$ y $\langle \hat{y}^2(t) \rangle$, tal como se muestra en la Figura 3. En ausencia de ruido (Figura 3a) la trayectoria presenta una estructura regular y altamente reproducible, reflejando la naturaleza determinística de la evolución. En contraste, la Figura 3b exhibe una deformación apreciable de dicha trayectoria como consecuencia de las fluctuaciones en la frecuencia de rotación. Aunque la órbita conserva las características generales asociadas al confinamiento dinámico, se observa una dispersión adicional que evidencia la sensibilidad de los segundos momentos frente a perturbaciones estocásticas de la trampa.


Estos resultados indican que los observables considerados son capaces de registrar de manera clara la presencia de ruido en la dinámica, manteniendo al mismo tiempo una relación estrecha con los parámetros físicos subyacentes. Esta característica resulta especialmente relevante para los objetivos de este trabajo, ya que permite generar conjuntos de datos sintéticos que reproducen condiciones experimentales realistas y que posteriormente serán utilizados para entrenar los modelos de inferencia basados en redes neuronales. Un análisis semejante puede realizarse también para los segundos momentos de los impulsos $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$ donde se exhibe este mismo comportamiento (ver Apéndice A).

3.1.1. Estimación de parámetros físicos por medio de redes neuronales

La Tabla 1 resume los resultados obtenidos con las dos arquitecturas de redes neuronales (NN) implementadas. La primera de ellas $\text{NN}_{(\Omega, \Gamma_x, \Gamma_y)}$ fue entrenada para inferir únicamente los parámetros físicos principales del sistema, correspondientes a la frecuencia de rotación de la trampa Ω y a las tasas de decoherencia Γ_x y Γ_y . La segunda arquitectura $\text{NN}_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)}$ incorporó además los parámetros característicos del proceso estocástico de Ornstein-Uhlenbeck, es decir, el tiempo de correlación τ_c y la amplitud del ruido σ . En ambos casos, las predicciones obtenidas resultan compatibles con los valores utilizados para generar los datos sintéticos dentro de las incertidumbres estimadas mediante la generación de réplicas artificiales de los datos observados. Este resultado indica que la información contenida en las series temporales de los segundos momentos es suficiente para reconstruir los parámetros relevantes del sistema a partir de observaciones indirectas.



(a)



(b)

Figura 3: Diagrama de fases para los valores medios de $\langle \hat{x}^2(t) \rangle$ y $\langle \hat{y}^2(t) \rangle$: **(a)** cuando no hay ruido estocástico ($\xi(t) = 0 \forall t$) y **(b)** cuando existe ruido estocástico en la frecuencia de rotación de la trampa, utilizando como parámetros $\tau_c = 0,3 \mu s$ y $\sigma = 0,3 \mu s^{-1}$.

	$\Omega \ (\mu s^{-1})$	$\Gamma_x \ (\mu s^{-1})$	$\Gamma_y \ (\mu s^{-1})$	$\tau_c \ (\mu s)$	$\sigma \ (\mu s^{-1})$
Datos simulados	2.70604	$5,081255 \times 10^{-5}$	$1,016251 \times 10^{-4}$	1.00	0.30
$NN_{(\Omega, \Gamma_x, \Gamma_y)}$	$2,70 \pm 0,22$	$(5,00 \pm 0,50) \times 10^{-5}$	$(1,00 \pm 0,08) \times 10^{-4}$	—	—
$NN_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)}$	$2,73 \pm 0,17$	$(4,92 \pm 0,76) \times 10^{-5}$	$(1,07 \pm 0,17) \times 10^{-4}$	$0,96 \pm 0,09$	$0,31 \pm 0,04$

Tabla 1: Comparación entre los valores utilizados en las simulaciones y los parámetros inferidos mediante las dos arquitecturas de red neuronal (NN).

La frecuencia de rotación constituye uno de los parámetros mejor identificados por ambas redes neuronales. Comparado el valor utilizado en las simulaciones, las redes $NN_{(\Omega, \Gamma_x, \Gamma_y)}$ y $NN_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)}$ predicen, respectivamente:

$$NN_{(\Omega, \Gamma_x, \Gamma_y)} : \quad \Omega = 2,70 \pm 0,22 \mu s^{-1} \quad , \quad NN_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)} : \quad \Omega = 2,73 \pm 0,17 \mu s^{-1}$$

En ambos casos la diferencia relativa respecto del valor nominal es inferior al 1 %. Asimismo, se observa una ligera reducción de la incertidumbre al incorporar los parámetros del ruido dentro del entrenamiento. Esto sugiere que una parte de las fluctuaciones presentes en los observables es explicada explícitamente por la dinámica estocástica modelada, evitando que dichas variaciones sean absorbidas artificialmente por la estimación de Ω .

Las tasas de decoherencia también son reconstruidas satisfactoriamente por ambas arquitecturas. Para la tasa de decoherencia en la dirección x , las estimaciones obtenidas son:

$$NN_{(\Omega, \Gamma_x, \Gamma_y)} : \quad \Gamma_x = (5,00 \pm 0,50) \times 10^{-5} \mu s^{-1} \quad , \quad NN_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)} : \quad \Gamma_x = (4,92 \pm 0,76) \times 10^{-5} \mu s^{-1}$$

para la primera y segunda red, respectivamente. De manera análoga, para la tasa de decoherencia en la dirección y se obtienen las predicciones:

$$NN_{(\Omega, \Gamma_x, \Gamma_y)} : \quad \Gamma_y = (1,00 \pm 0,08) \times 10^{-4} \mu s^{-1} \quad , \quad NN_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)} : \quad \Gamma_y = (1,07 \pm 0,17) \times 10^{-4} \mu s^{-1}$$

Las discrepancias observadas son pequeñas y permanecen dentro de los intervalos de confianza obtenidos. Sin embargo, las incertidumbres relativas asociadas a las tasas de decoherencia son mayores que las correspondientes a la frecuencia de rotación. Desde el punto de vista físico, este comportamiento es razonable, ya que Ω modifica directamente la estructura temporal de las oscilaciones observadas en los segundos momentos, mientras que los efectos de Γ_x y Γ_y se manifiestan de manera acumulativa y más gradual sobre la evolución temporal.

La principal ventaja de la segunda arquitectura radica en su capacidad para reconstruir simultáneamente los parámetros que caracterizan el proceso estocástico incorporado en las simulaciones. La red neuronal predice:

$$\tau_c = 0,96 \pm 0,09 \mu s \quad , \quad \sigma = 0,31 \pm 0,04 \mu s^{-1}$$

Ambas estimaciones presentan errores relativos inferiores al 10 %, lo cual resulta particularmente significativo considerando que estos parámetros no aparecen de forma explícita en los observables medidos. Su influencia se manifiesta únicamente a través de las fluctuaciones que inducen sobre la dinámica de los segundos momentos. En consecuencia, estos resultados sugieren que la red neuronal es capaz de identificar características estadísticas del ruido a partir de la información contenida en las trayectorias temporales.

Un resultado particularmente destacable es que la inclusión de dos parámetros adicionales en el espacio de salida no deteriora significativamente la reconstrucción de los parámetros físicos principales. A priori, podría esperarse que el aumento de la dimensionalidad del problema dificultara el entrenamiento y aumentara las incertidumbres asociadas a todas las variables inferidas. Sin embargo, los resultados muestran que la segunda red $NN_{(\Omega, \Gamma_x, \Gamma_y, \tau_c, \sigma)}$ mantiene una precisión comparable a la obtenida por la primera $NN_{(\Omega, \Gamma_x, \Gamma_y)}$.

Esto indica que los parámetros τ_c y σ dejan huellas suficientemente diferenciadas en la dinámica de los segundos momentos como para que la red pueda aprenderlas sin introducir una fuerte degeneración con los parámetros Ω , Γ_x y Γ_y . Si bien los resultados obtenidos son alentadores, es importante señalar que el entrenamiento se realizó utilizando un conjunto relativamente reducido de simulaciones. En consecuencia, las incertidumbres reportadas podrían estar dominadas por limitaciones estadísticas asociadas al tamaño del conjunto de entrenamiento más que por restricciones intrínsecas del método de inferencia. Un incremento en el número de simulaciones disponibles permitiría evaluar con mayor precisión la capacidad de generalización de las redes neuronales y reducir las fluctuaciones estadísticas observadas.

No obstante, los resultados obtenidos muestran que las redes neuronales constituyen una herramienta prometedora para abordar problemas inversos en sistemas optomecánicos levitados. En particular, la capacidad de reconstruir simultáneamente parámetros dinámicos y parámetros asociados al ruido sugiere que estos métodos podrían emplearse en futuras aplicaciones experimentales orientadas a la caracterización de mecanismos de decoherencia y fuentes de fluctuaciones técnicas en plataformas cuánticas mesoscópicas.

3.2. Trampa armónica con mecanismos de *feedback-cooling*

Para empezar con las simulaciones realizadas sobre la trampa con medición continua, se decidió poner a prueba los filtros de Kalman como método de ajuste para trayectorias medidas. Para esto, se simuló una trayectoria por $500 \mu s$, y se utilizó un filtro de Kalman extendido para inferir el estado del sistema a partir de las mediciones de la posición. Se muestran los valores medidos, verdaderos, e inferidos para cada variable del sistema estocástico en la Figura 4. Para el caso de las trayectorias inferidas, se muestra sombreada el área de 95 % de confianza de las mismas basado en la covarianza estimada por el filtro de Kalman y la gaussianidad aproximada de la distribución de las mismas. Se puede notar que el filtro de Kalman




Figura 4: Aplicación de un filtro de Kalman extendido a la inferencia de los valores medios de las variables del sistema dadas observaciones una trayectoria del mismo.

ajusta correctamente el comportamiento de la posición y el momento, pero menos correctamente el comportamiento del momento estimado. Se cree que esto está relacionado al hecho de que, al no ser directamente medido ni participar de las ecuaciones de movimiento para el valor medio de la posición, para inferir este último se debe realizar una inferencia más indirecta que la realizada para la posición o el momento. También se puede observar que el filtro de Kalman funciona peor

al llegar al estado estacionario, en que la importancia de la dinámica determinista disminuye frente al ruido. Sin embargo, se ve que aunque en este régimen los valores medios del estado estimado no siguen tan cercanamente al estado real como en el régimen transitorio, esto se compensa con un aumento en la dispersión estimada para los parámetros. Una última falencia, especialmente observable para el momento estimado, es que al principio, al no tener demasiadas mediciones todavía en que basarse, la estimación del estado puede no ser muy precisa. A pesar de todo esto, en términos generales, se juzga que el filtro de Kalman logra dar una aproximación razonable de la evolución del estado del sistema en base a las mediciones proporcionadas. Para poner en prueba esta suposición se puso a prueba la efectividad de los filtros de Kalman dos problemas de optimización directa e inversa.

3.2.1. Inferencia de parámetros

Como problema de optimización inversa, también de utilidad práctica, se decidió probar si los filtros de Kalman permitirían inferir el orden de magnitud de algunos parámetros del mecanismo de retroalimentación a los que sería difícil de acceder experimentalmente. En particular, se consideró por separado el caso de v_x y ϵ_x , la tasa de convergencia y magnitud del ruido para la estimación del momento. Las variaciones de los mismos fueron parametrizadas a partir de un exponente e tal que los valores de prueba de los parámetros fuesen $\tilde{v}_x = v_x \cdot 10^e$ o $\tilde{\epsilon}_x = \epsilon_x \cdot 10^e$. En cada caso, se generó un set de 1000 trayectorias de $500 \mu s$ con los parámetros estándar del sistema, y se calculó para distintos valores de los parámetros a ajustar el valor de la función de pérdida, definida como:

$$\mathcal{L} = -\log \left(\left\langle L(\theta | \{\tilde{u}_{i,t_i:t_f}^{OBS}\}) \right\rangle \right), \quad (27)$$

en donde $\left\langle L(\theta | \{\tilde{u}_{i,t_i:t_f}^{OBS}\}) \right\rangle$ es la verosimilitud media de los parámetros a ajustar (θ) en base al conjunto de trayectorias provisto, tal como fue definida en la ecuación 22. En el cálculo de esta función de pérdida, la única fuente de aleatoriedad es el conjunto de trayectorias utilizado, ya que, a diferencia de los filtros de partículas, los filtros de Kalman asignan un valor de verosimilitud a cada trayectoria de forma completamente determinista. Gracias a esto, se decidió asignar un error al cálculo de la función de pérdida basado en un bootstrap no paramétrico de las trayectorias incluidas en el conjunto, caracterizando así la dependencia del valor obtenido respecto al conjunto de trayectorias generado. Los resultados para la función de error se muestran en la Figura 5




Figura 5: Función de pérdida calculada a partir de un conjunto de 1000 trayectorias simuladas ante variaciones exponenciales de (a) la tasa de convergencia del momento estimado al momento real en x y (b) la magnitud del ruido considerado sobre la dinámica del momento estimado en x .

Se puede ver en ambos casos que las curvas presentan un mínimo cercano a $e = 0$, que corresponde al valor real de cada parámetro y apoya nuestro uso de filtros de Kalman para modelar el sistema. Sin embargo, el comportamiento de las dos curvas es notoriamente distinto. Para la tasa de convergencia v_x , el mínimo hallado es pronunciado a ambos lados, mientras que para la magnitud del ruido ϵ_x , el mínimo es pronunciado únicamente en una dirección (lo que sugiere que la presencia de ruido sobre la estimación no es detectable mientras que su magnitud sea menor a un cierto valor). En términos prácticos, esto indica que un proceso de optimización permitiría ajustar el valor del primer parámetro a los datos, mientras que esto sería más difícil para el segundo, en que tal vez solo se permitiría obtener una cota. Vale la pena notar la magnitud considerable del error considerado para la función de pérdida, siendo esta no despreciable frente a la profundidad del mínimo en especial para el parámetro ϵ_x . Esto sugiere que las curvas halladas (y en particular la posición o existencia del mínimo) dependen

fuertemente del conjunto de trayectorias generado, lo cual podría llevar a ajustes poco confiables de los parámetros. No obstante, existirán correlaciones fuertes entre estos errores, ya que la verosimilitud de un cierto valor de un parámetro no será independiente de la verosimilitud de valores vecinos, por lo que se debería realizar a futuro un análisis más detallado de la forma de esta curva ante distintos conjuntos de trayectorias.

3.2.2. Minimización de covarianza a tiempos largos

Como problema de optimización directa, se escogió el de la minimización de las fluctuaciones en los valores medios de la posición en un tiempo tardío en que el sistema habría parcialmente decaído hacia un estado estacionario ($500 \mu s$). Este idea surge del objetivo final de la retroalimentación, que es enfriar el sistema. Se escogió la traza de la matriz de covarianza de la posición como indicador de la presencia de fluctuaciones en de en la posición, mientras que los parámetros a variar fueron u_x y u_y , las constantes de proporcionalidad entre el momento estimado y la fuerza aplicada sobre el sistema en cada dirección.

Para realizar la optimización, se utilizó un filtro de Kalman no condicionado por mediciones, utilizándolo para propagar las propiedades medias y varianza del estado del sistema hasta el tiempo escogido, y calcular a este tiempo el estimador. El problema fue resuelto según el método de gradiente descendiente utilizando diferenciación automática en modo directo, obteniendo valores óptimos para los parámetros de $u_{x0} \approx 0,467$ y $u_{y0} \approx 0,534$. Basado en estos resultados se realizó también un barrido exponencial de parámetros alternativos centrado en los óptimos para u_x y u_y , calculando para cada combinación la traza de la matriz de covarianza de los valores medios de posición (nuestra función de pérdida). Por último, se realizaron simulaciones del comportamiento del estimador de las fluctuaciones, tanto mediante los filtros de Kalman como mediante la integración numérica de 1000 trayectorias, para valores de u_x y u_y dados por los óptimos ($\vec{u}_0$) o dos otros proporcionales a estos ($10 \cdot \vec{u}_0$ y $1/10 \cdot \vec{u}_0$). Los resultados de estas simulaciones se encuentran en la Figura 6.




Figura 6: (a) Comportamiento de la traza de la matriz de covarianza de los valores medios de posición en el tiempo para distintos valores de u_x y u_y . Se muestran con líneas sólidas los valores predichos por los filtros de Kalman y con líneas punteadas los obtenidos mediante integración numérica. (b) Valor predicho mediante filtros de Kalman para la traza de la matriz de covarianza para valores de u_x y u_y exponencialmente distribuidos alrededor de los óptimos.

Se puede ver que la función a minimizar presenta un mínimo claro cercano a los parámetros óptimos, aunque presenta algunos mínimos locales separados por barreras poco pronunciadas en las zonas lejanas a estos que podrían eventualmente interferir con un proceso de optimización si los parámetros iniciales no fuesen adecuados. Sin embargo, las regiones afectadas por estas barreras débiles son pequeñas y para casi todos los parámetros censados no se observan obstáculos entre ellos y el mínimo hallado. Se puede observar que el comportamiento de las fluctuaciones de la posición predicho por los filtros de Kalman, aunque presenta algunas diferencias, es un buen estimador del comportamiento obtenido por la integración numérica, que es más costosa computacionalmente. Nuevamente, esto refuerza la elección de utilizar filtros de Kalman para modelar este sistema.

4. Discusión y conclusión

En este trabajo se estudió la dinámica cuántica de una nanopartícula levitada en una trampa óptica tipo *saddle*, utilizando un modelo basado en ecuaciones maestras de Lindblad para describir simultáneamente la evolución coherente del sistema y los mecanismos de decoherencia asociados al entorno. La dinámica fue analizada en el régimen cuadrático del potencial,

permitiendo describir la evolución temporal de los segundos momentos de posición e impulso, magnitudes que contienen la información física relevante del sistema.

Con el objetivo de aproximar escenarios experimentales más realistas, se incorporó un ruido estocástico en la frecuencia de rotación de la trampa mediante un proceso de Ornstein-Uhlenbeck. El análisis de las simulaciones mostró que, bajo los valores utilizados, este mecanismo introduce modificaciones apreciables en la evolución temporal de los observables sin alterar cualitativamente la dinámica de confinamiento. Asimismo, se verificó que los parámetros elegidos para caracterizar el ruido generan fluctuaciones comparables a las que podrían encontrarse en una implementación experimental, permitiendo construir un conjunto de datos sintéticos con un mayor grado de realismo.

A partir de estas simulaciones se abordó el problema inverso de inferir parámetros físicos del sistema a partir de observables accesibles experimentalmente. Para ello se entrenaron redes neuronales utilizando como entradas las series temporales de los segundos momentos y como salidas los parámetros que gobiernan la dinámica. Los resultados obtenidos muestran que la información contenida en dichos observables resulta suficiente para reconstruir con buena precisión las tasas de decoherencia y la frecuencia de rotación efectiva de la trampa. Se observó que la frecuencia de rotación constituye el parámetro más identificable por las redes neuronales, mientras que las tasas de decoherencia presentan incertidumbres relativamente mayores debido a que sus efectos sobre la dinámica se manifiestan de manera más gradual. A pesar de ello, todas las estimaciones obtenidas resultaron compatibles con los valores nominales utilizados para generar los datos sintéticos dentro de los intervalos de confianza calculados.

Además, se exploró una segunda arquitectura capaz de inferir simultáneamente los parámetros físicos y los parámetros característicos del ruido estocástico. Los resultados indican que la inclusión de τ_c y σ en el espacio de salida no degrada significativamente la capacidad predictiva de la red, sugiriendo que las huellas asociadas al ruido permanecen codificadas en la evolución temporal de los observables y pueden ser identificadas mediante técnicas de aprendizaje automático. Por otra parte, se pudo estimar las incertidumbres asociadas a los parámetros inferidos, proporcionando una caracterización estadística de la robustez de las predicciones obtenidas.

Por otra parte, se realizó un estudio del mismo sistema teniendo en cuenta mecanismos de monitoreo y retroalimentación, resultando en un modelo efectivo caracterizado por un sistema de ecuaciones diferenciales estocásticas. Se modeló la dinámica del sistema utilizando filtros de Kalman extendidos como complemento a la integración numérica directa y alternativa menos computacionalmente intensa a los filtros de partículas. Se encontró que los filtros de Kalman extendidos proveen de una herramienta efectiva para modelar el sistema y sus mecanismos de retroalimentación en el rango de parámetros considerado, tanto para problemas directos como para problemas inversos. Los dos problemas de optimización afrontados mediante los filtros de Kalman lograron demostrar su utilidad práctica para el ajuste de parámetros experimentalmente poco accesibles y optimización de los mecanismos de enfriado. Así, se concluye que estos resultan una herramienta prometedora de diagnóstico y diseño para este sistema.

Como perspectivas futuras, resulta natural extender este enfoque a conjuntos de datos de mayor tamaño, optimización sobre un mayor número de parámetros o incorporar modelos de ruido más complejos, en especial para la estimación del momento en la trampa monitoreada. Asimismo, sería de especial interés aplicar estas metodologías directamente sobre datos experimentales reales, evaluando su capacidad para caracterizar sistemas levitados fuera de las condiciones idealizadas consideradas en este trabajo.

5. Datos y software

La dinámica de la nanopartícula en la trampa óptica *saddle* fue simulada resolviendo numéricamente la ecuación maestra de Lindblad dada por la ecuación (8). Para ello se utilizó la biblioteca *Quantum Toolbox in Python* (QuTiP), ampliamente empleada para la simulación de sistemas cuánticos abiertos. Las simulaciones permitieron obtener la evolución temporal de los valores medios de los observables $\langle \hat{x}^2(t) \rangle$, $\langle \hat{y}^2(t) \rangle$, $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$, que posteriormente fueron utilizados para el análisis estadístico y el entrenamiento de las redes neuronales. Los datos empleados a lo largo del trabajo fueron enteramente sintéticos y generados a partir de las simulaciones numéricas descritas anteriormente.

Un aspecto técnico importante consistió en la interpolación numérica de la fase $\phi(t)$ asociada a la rotación de la trampa. Esto fue necesario debido a que los integradores internos utilizados por QuTiP emplean pasos temporales adaptativos que no coinciden necesariamente con la discretización temporal elegida para almacenar los resultados de la simulación. La interpolación permitió evaluar consistentemente los coeficientes dependientes del tiempo del Hamiltoniano durante la integración numérica.

Para la resolución del problema inverso de inferencia de parámetros cuando se presenta ruido estocástico en la frecuencia de giro de la trampa, se implementaron redes neuronales utilizando la biblioteca PyTorch. El preprocesamiento de los datos, la generación de ruido estocástico, los procedimientos de normalización, el análisis estadístico y la estimación de incertidumbres fueron realizados utilizando las bibliotecas NumPy, SciPy y Matplotlib dentro del entorno de programación Python.

Para el modelado de la trampa monitoreada, la integración numérica de las trayectorias de los segundos momentos según la ecuación (17) se realizó utilizando el paquete *DifferentialEquations.jl*, mientras que la simulación de las ecuaciones (16) que determinan la dinámica de los valores medios se realizó mediante la librería *Gen.jl*. Los filtros de Kalman extendidos fueron implementados por la librería *LowLevelParticleFilters.jl* y la optimización se realizó mediante la librería *Optimization.jl* del entorno SciML de Julia.

Todos los cálculos numéricos, simulaciones y procedimientos de aprendizaje automático fueron desarrollados íntegramente en Python y Julia, garantizando la reproducibilidad de los resultados obtenidos mediante scripts propios encontrados en

Referencias

- [1] U. DeliĆ, M. Reisenbauer, K. Dare, D. Grass, V. VuletiĆ, N. Kiesel, and M. Aspelmeyer. Cooling of a levitated nanoparticle to the motional quantum ground state. *Science*, 367(6480):892–895, 2020.
- [2] L. Magrini, P. Rosenzweig, C. Bach, A. Deutschmann-Olek, S. G. Hofer, S. Hong, N. Kiesel, A. Kugi, and M. Aspelmeyer. Real-time optimal quantum control of mechanical motion at room temperature. *Nature*, 595:373–377, 2021.
- [3] F. Tebbenjohanns, M. L. Mattana, M. Rossi, M. Frimmer, and L. Novotny. Quantum control of a nanoparticle optically levitated in cryogenic free space. *Nature*, 595:378–382, 2021.
- [4] A. Ranfagni, K. Børkje, F. Marino, and F. Marin. Two-dimensional quantum motion of a levitated nanosphere. *Physical Review Research*, 4:033051, 2022.
- [5] M. Kamba, R. Shimizu, and K. Aikawa. Optical cold damping of neutral nanoparticles near the ground state in an optical lattice. *Optics Express*, 30:26716–26728, 2022.
- [6] J. Piotrowski, D. Windey, J. Vijayan, C. Gonzalez-Ballester, A. de los Ríos Sommer, N. Meyer, R. Quidant, O. Romero-Isart, R. Reimann, and L. Novotny. Simultaneous ground-state cooling of two mechanical modes of a levitated nanoparticle. *Nature Physics*, 19:1009–1013, 2023.
- [7] L. Dania, O. S. Kremer, J. Piotrowski, D. Candoli, J. Vijayan, O. Romero-Isart, C. Gonzalez-Ballester, L. Novotny, and M. Frimmer. High-purity quantum optomechanics at room temperature. *Nature Physics*, 21:1603–1608, 2025.
- [8] R. Muffato, T. Georgescu, J. Homans, T. Guerreiro, Q. Wu, D. Chisholm, M. Carlesso, M. Paternostro, and H. Ulbricht. Generation of classical non-gaussian states by squeezing a thermal state into nonlinear motion of levitated optomechanics. *Physical Review Research*, 7:013171, 2025.
- [9] E. Bonvin, L. Devaud, M. Rossi, A. Militaru, L. Dania, D. S. Bykov, O. Romero-Isart, T. E. Northup, L. Novotny, and M. Frimmer. State expansion of a levitated nanoparticle in a dark harmonic potential. *Physical Review Letters*, 132:253602, 2024.
- [10] M. Rossi, A. Militaru, N. Carlon Zambon, A. Riera-Campen, O. Romero-Isart, M. Frimmer, and L. Novotny. Quantum delocalization of a levitated nanoparticle. *Physical Review Letters*, 135:083601, 2025.
- [11] M. L. Mattana, N. C. Zambon, M. Rossi, E. Bonvin, L. Devaud, M. Frimmer, and L. Novotny. Trap-to-trap free falls with an optically levitated nanoparticle. *Physical Review A*, 113:023510, 2026.
- [12] J. Rieser, M. A. Ciampini, H. Rudolph, N. Kiesel, K. Hornberger, B. A. Stickler, M. Aspelmeyer, and U. DeliĆ. Tunable light-induced dipole-dipole interaction between optically levitated nanoparticles. *Science*, 377:987–990, 2022.
- [13] J. Vijayan, J. Piotrowski, C. Gonzalez-Ballester, K. Weber, O. Romero-Isart, and L. Novotny. Cavity-mediated long-range interactions in levitated optomechanics. *Nature Physics*, 20:859–864, 2024.
- [14] Q. Deplano, A. Pontin, A. Ranfagni, F. Marino, and F. Marin. Coulomb coupling between two nanospheres trapped in a bichromatic optical tweezer. *Optica*, 11:1773–1779, 2024.
- [15] M. Skrabulis, M. C. Sosa, N. C. Zambon, A. Militaru, M. Rossi, M. Frimmer, and L. Novotny. Nanomechanical sensor resolving impulsive forces below its zero-point fluctuations. *arXiv preprint arXiv:2601.19392*, 2026.
- [16] G. Marocco, D. C. Moore, and D. Carney. Three-dimensional squeezing of optically levitated nanospheres. *arXiv preprint arXiv:2601.22283*, 2026.
- [17] P. L. Kapitza. Dynamical stability of a pendulum when its point of suspension vibrates, and pendulum with a vibrating suspension. *Collected papers of PL Kapitza*, 2:714, 1965.
- [18] W. Paul. Electromagnetic traps for charged and neutral particles. *Reviews of modern physics*, 63:531, 1990.
- [19] A. Ashkin and J. Dziedzic. Optical levitation in high vacuum. *Applied Physics Letters*, 28:333, 1976.
- [20] J. Gieseler, J. R. Gomez-Solano, A. Magazzù, I. P. Castillo, García L. P., M. Gironella-Torrent, X. Viader-Godoy, F. Ritort, G. Pesce, A. V. Arzola, et al. Optical tweezers—from calibration to applications: a tutorial. *Advances in Optics and Photonics*, 13:74, 2021.
- [21] J. Millen, T. S. Monteiro, R. Pettit, and A. N. Vamivakas. Optomechanics with levitated particles. *Reports on Progress in Physics*, 83:026401, 2020.

- [22] C. Gonzalez Ballester, M. Aspelmeyer, L. Novotny, R. Quidant, and O. Romero-Isart. Levitodynamics: Levitation and control of microscopic objects in vacuum. *Science*, 374:3027, 2021.
- [23] D. S. Bykov, M. Meusburger, L. Dania, and T. E. Northup. Hybrid electro-optical trap for experiments with levitated particles in vacuum. *Review of scientific instruments*, 93, 2022.
- [24] O. Romero-Isart. Quantum superposition of massive objects and collapse models. *Physical Review A*, 84:052121, 2011.
- [25] E. Joos et al. Decoherence and the appearance of a classical world in quantum theory. *Springer, Heidelberg*, 2003.
- [26] P. Blanchard, D. Giulini, E. Joos, C. Kiefer, and I. Stamatescu. Decoherence: Theoretical, experimental, and conceptual problem. *Lecture Notes in Physics, Springer, Heidelberg*, page 538, 2000.
- [27] Y. Imry. Introduction to mesoscopic physics 2nd edn. *Oxford Univ. Press, Oxford*, 2000.
- [28] W. H. Zurek. Decoherence, einselection, and the quantum origins of the classical. *Rev. Mod. Phys.*, 75:715–775, 2003.
- [29] T. Pfau, S. Spalter, Ch. Kurtsiefer, C. R. Ekstrom, and Mlynec J. Loss of spatial coherence by a single spontaneous emission. *Phys. Rev. Lett.*, 73:1223–1226, 1994.
- [30] M. S. Chapman et al. Photon scattering from atoms in an atom interferometer: coherence lost and regained. *Phys. Rev. Lett.*, 75:3783–3787, 1995.
- [31] D. A. Kokorowski, A. D. Cronin, T. D. Roberts, and D. E. Pritchard. From single- to multiple-photon decoherence in an atom interferometer. *Phys. Rev. Lett.*, 86:2191–2194, 2001.
- [32] K. Hornberger et al. Collisional decoherence observed in matter wave interferometry. *Phys. Rev. Lett.*, 90:160401, 2003.
- [33] Y. Ji et al. An electronic mach-zehnder interferometer. *Nature*, 415:415–418, 2003.
- [34] E. Buks, R. Schuster, M. Heiblum, D. Mahalu, and V. Umansky. Dephasing in electron interference by a 'which-path' detector. *Nature*, 391:871–874, 1998.
- [35] C. J. Myatt et al. Decoherence of quantum superpositions through coupling to engineered reservoirs. *Nature*, 403:269–273, 2000.
- [36] M. Brune et al. Observing the progressive decoherence of the "meter" in a quantum measurement. *Phys. Rev. Lett.*, 77:4887–4890, 1996.
- [37] L. Hackermüller, K. Hornberger, B. Brezger, A. Zeilinger, and M. Arndt. Decoherence of matter waves by thermal emission of radiation. *Nature*, 427:711–714, 2004.
- [38] V. Jain, J. Gieseler, C. Moritz, C. Dellago, R. Quidant, and L. Novotny. Direct measurement of photon recoil from a levitated nanoparticle. *Physical review letters*, 116:243601, 2016.
- [39] P. V. Paraguassú, L. Abrahão, D. Tandeitnik, D. Martínez-Tibaduiza, A. Z. Khoury, and T. Guerreiro. All-optical saddle trap as a platform for mesoscopic quantum experiments. *arXiv preprint arXiv:2605.00724*, 2026.
- [40] Lorenzo Dania, Katharina Heidegger, Dmitry S. Bykov, Giovanni Cerchiari, Gabriel Araneda, and Tracy E. Northup. Position measurement of a levitated nanoparticle via interference with its mirror image. *Physical Review Letters*, 129(1), 6 2022.
- [41] Yu Zheng, Lei-Ming Zhou, Yang Dong, Cheng-Wei Qiu, Xiang-Dong Chen, Guang-Can Guo, and Fang-Wen Sun. Robust optical-levitation-based metrology of nanoparticle's position and mass. *Physical Review Letters*, 124(22), 6 2020.
- [42] D. Tandeitnik, O. Kremer, F. Almeida, J. A. Zielińska, A. Z. Khoury, and T. Guerreiro. All-optical saddle trap. *Physical Review Applied*, 22(4):044073, 2024.
- [43] M. Roda-Llodes, D. Candoli, P. T. Grochowski, A. Riera-Campeny, T. Agrenius, J. J. García-Ripoll, C. Gonzalez-Ballester, and O. Romero-Isart. Numerical simulation of large-scale nonlinear open quantum mechanics. *Physical Review Research*, 6(1):013262, 2024.
- [44] T. Weiss, E. Roda-Llodes, M. and Torrontegui, M. Aspelmeyer, and O. Romero-Isart. Large quantum delocalization of a levitated nanoparticle using optimal control: Applications for force sensing and entangling via weak forces. *Physical Review Letters*, 127(2):023601, 2021.
- [45] T. Seberston and F. Robicheaux. Distribution of laser shot-noise energy delivered to a levitated nanoparticle. *Phys. Rev. A*, 102:033505, Sep 2020.
- [46] Crispin W. Gardiner. Handbook of stochastic methods for physics, chemistry and the natural sciences. *Springer Series in Synergetics*, 1985.

- [47] M. Jost, M. Schaffner, M. Magno, M. Korb, L. Benini, R. Reimann, V. Jain, M. Grossi, A. Militara, M. Frimmer, and L. Novotny. An accurate system for optimal state estimation of a levitated nanoparticle. In *2018 IEEE Sensors Applications Symposium (SAS)*, pages 1–6, 2018.
- [48] Chapters 7, 8. In Andrew H. Jazwinski, editor, *Stochastic Processes and Filtering Theory*, volume 64 of *Mathematics in Science and Engineering*, pages 194–331. Elsevier, 1970.

A. Trampa armónica con ruido estocástico: comportamiento de los segundos momentos del impulso

La Figura 7 presenta las series temporales de $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$. En la imagen de la izquierda (Figura 7a) se encuentra el caso determinístico, correspondiente al límite $\sigma \rightarrow 0$ y $\tau_c \rightarrow +\infty$, donde la frecuencia de rotación permanece estrictamente constante ($\xi(t) = 0 \forall t$) y en la Figura 7b se muestra la evolución de los mismos observables cuando la frecuencia de rotación incorpora fluctuaciones descritas por un proceso de Ornstein-Uhlenbeck. Se aprecia como sucede lo mismo que en los casos estudiados para $\langle \hat{x}^2(t) \rangle$ y $\langle \hat{y}^2(t) \rangle$, donde la estructura global de la dinámica permanece reconocible, indicando que el sistema continúa operando dentro del mismo régimen físico y que las fluctuaciones introducidas no dominan completamente la evolución temporal. Para esta simulación, se utilizaron los valores $\tau_c = 0,3 \mu s$ y $\sigma = 0,3 \mu s^{-1}$.




Figura 7: Series temporales para los valores medios de $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$: **(a)** cuando no hay ruido estocástico ($\xi(t) = 0 \forall t$) y **(b)** cuando existe ruido estocástico en la frecuencia de rotación de la trampa, utilizando como parámetros $\tau_c = 0,3 \mu s$ y $\sigma = 0,3 \mu s^{-1}$.

Por otro lado, se quiere representar la evolución temporal en el espacio de fases definido por los segundos momentos $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$, tal como se muestra en la Figura 8. En ausencia de ruido (Figura 8a) la trayectoria presenta una estructura regular y altamente reproducible, reflejando la naturaleza determinística de la evolución. En contraste, la Figura 8b exhibe una deformación apreciable de dicha trayectoria como consecuencia de las fluctuaciones en la frecuencia de rotación.




Figura 8: Diagrama de fases para los valores medios de $\langle \hat{p}_x^2(t) \rangle$ y $\langle \hat{p}_y^2(t) \rangle$: **(a)** cuando no hay ruido estocástico ($\xi(t) = 0 \forall t$) y **(b)** cuando existe ruido estocástico en la frecuencia de rotación de la trampa, utilizando como parámetros $\tau_c = 0,3 \mu s$ y $\sigma = 0,3 \mu s^{-1}$.

B. Evolución de los segundos momentos en la trampa monitoreada

En las experiencias utilizando la trampa con medición continua y retroalimentación, se ha puesto mucho énfasis en la evolución de los valores medios de posición y momento y comparativamente menos en la evolución de las otras variables dinámicas de las ecuaciones 16 y 17, los segundos momentos de las distribuciones. Esto se debe a que las ecuaciones que rigen su comportamiento son deterministas y desacopladas de las de los valores medios, como se explicó en la sección 2.3. Al ser su estado inicial siempre el mismo, las trayectorias también lo serán. Estas trayectorias se muestran en la Figura 9.

Segundos momentos de la distribución




Figura 9: Evolución de los segundos momentos de posición y momento de acuerdo a las ecuaciones 17.